

# Formulación automática de modelos de optimización


Adaptación QLoRA y evaluación frente a la línea base

Entrega 2 | Inteligencia Artificial Generativa (580694)

Rayen Muñoz, Isidora Rivera, Sebastián Soto y José Luis Erices

**Por qué importa.** Omitir la población al localizar centros cambia a quién prioriza el objetivo; omitir el vínculo de apertura permite atender sectores desde centros cerrados. El sistema produce borradores paramétricos para revisión experta.

## Pipeline del experimento



## 1 Continuidad y elección

La tarea de la Entrega 1 sigue intacta: traducir enunciados LP/MILP a conjuntos, parámetros, variables, objetivo y restricciones *equivalentes*, sin resolver el óptimo. En el caso oftalmológico, el modelo original falló en apertura, asignación y ponderación poblacional.

$$\begin{aligned} \min \sum_{i,j} p_j d_{ij} x_{ij}, \quad & \sum_i y_i = 2, \\ \sum_i x_{ij} = 1 \quad (\forall j), \quad & x_{ij} \leq y_i \quad (\forall i, j). \end{aligned}$$

Se eligió **Qwen2.5-1.5B-Instruct**, revisión 989aa7980e4c, frente a Gemma-2-2B-IT (2B) y Phi-3-mini (3.8B): el menor de los tres, ejecutable en T4. Todos cometieron errores de modelación en la Entrega 1.

En una corrida por variante del caso, la rúbrica previa de localización dio 1,65/5 al prompt directo, 1,35/5 al razonamiento paso a paso y 1,00/5 a la descomposición. Se exploraron también verificación con código, selección de respuestas, one-shot y representación intermedia; persistieron fallas estructurales. Estos puntajes usan **otra rúbrica**.

## 2 Intervención y datos

**QLoRA** entrena matrices de bajo rango sobre una base congelada y cuantizada en 4 bits (NF4). Una época usó 1050 pares sintéticos: 50 familias con 21 variantes cada una (315 LP, 735 MILP), LoRA  $r = 16$ ,  $\alpha = 32$ , semilla 42 y pérdida solo sobre la respuesta. En Colab T4: **982 s, 131 pasos y 9,04 GiB** reservados.

## 3 Contraste del caso oftalmológico

En la ejecución demostrativa, la salida pasó de **1140 a 232 tokens** (49,3 a 15,6 s). La respuesta ajustada siguió las secciones pedidas, declaró  $y_i$  y  $x_{ij}$ , e incorporó cardinalidad, asignación única y vínculo  $x_{ij} \leq y_i$ . La respuesta base inventó una ínsolución óptima y careció de  $y_i$ .

**Mejora parcial.** QLoRA todavía omitió  $p_j$  del objetivo:  $\min \sum d_{ij} x_{ij}$  no minimiza distancia ponderada por población. En las respuestas archivadas de este caso, FOM-5 v2 pasó de **0,650 a 3,850/5**; el caso se reporta fuera de la media de 30.


## 4 Benchmark y resultados

La comparación usa los **mismos 30 enunciados**, generación determinista y tope de 1200 tokens. Se conservaron 30 respuestas base y se generaron 30 QLoRA. Qwen3-14B NF4 juzgó ambas; referencia y requisitos entraron solo en la evaluación. **FOM-5 v2** puntúa de 0 a 5 decisiones y dominios  $D$  (15 %), objetivo  $O$  (20 %), restricciones  $R$  (35 %), validez algebraica  $A$  (15 %) y generalización  $G$  (15 %):

$$F = 0,15D + 0,20O + 0,35R + 0,15A + 0,15G.$$

Los requisitos ausentes o erróneos limitan las dimensiones pertinentes. La misma rúbrica evaluó ambas condiciones.

| 30 problemas         | Base   | QLoRA         |
|----------------------|--------|---------------|
| FOM-5 v2 medio (0–5) | 0,5884 | <b>0,8024</b> |
| Casos con 0/5        | 21     | <b>12</b>     |



El cambio medio pareado fue **+0,2140/5**. El intervalo bootstrap del 95 % sobre 10000 remuestreos de las 30 diferencias es  $[-0,2136; +0,7007]$ . Incluye cero: **la mejora no es concluyente** para este conjunto.

## 5 Falla y alcance

En **opt\_02**, producción con horas extra, QLoRA bajó de **1,30 a 0,00/5**. Las horas  $h \in [0, 20]$  debían ampliar solo trabajo y costar  $10h$ ; el modelo inventó  $y_k$ , mezcló índices y omitió  $x_C \geq 10$ . Una plantilla aprendida sustituyó reglas del enunciado. La concisión y el mejor formato **no garantizan corrección matemática**. Cada familia comparte una formulación canónica; tres casos tuvieron exposición histórica previa. Una semilla y un juez automático limitan la inferencia. El paso siguiente es verificar cobertura de requisitos, dominios e índices antes de aceptar un borrador.

## 6 Ejecución y materiales

El notebook ejecuta ambas rutas sobre el mismo caso; los CSV guardan respuestas y juicios por ID. [Repositorio y código](#) [Video de ejecución](#).