

Formulación de modelos de optimización con QLoRA

Deliverable 2 — Generative Artificial Intelligence (580694)

Rayen Muñoz • Isidora Rivera • Sebastián Soto • José Luis Erices

Repositorio

GitHub

Notebook

Google Colab

Casos

30 problemas

Video

Google Drive

Objetivo convertir un enunciado en una formulación LP/MILP paramétrica y verificable, con un modelo de 1.5B en una GPU T4.

1. Tarea, falla y continuidad

Tarea (la misma de la Entrega 1).

- **Entrada:** el enunciado en español de un problema de programación lineal o lineal entera.
- **Salida:** conjuntos, parámetros, variables con su dominio, función objetivo y restricciones, sin resolver el óptimo.

Una respuesta es correcta si es equivalente a una formulación de referencia: símbolos definidos, índices consistentes, todos los requisitos presentes y ninguna condición inventada.

Por qué importa. Formular es la etapa lenta y propensa a errores de la optimización. Un borrador correcto ahorra trabajo al analista, apoya la docencia y acerca estos modelos a empresas sin especialistas.

Falla diagnosticada en la Entrega 1 (caso p-mediana)

Elegir 2 de 3 sitios y asignar 5 sectores minimizando la distancia ponderada por población. Qwen con prompting directo:

- **Omite la decisión de apertura** y_i : escribe $\sum_i x_{ij} = 2$ y $\sum_i x_{ij} = 1$ para todo j , que se contradicen.
- **Ignora la población** p_j en el objetivo.
- **Inventa restricciones** ($x_{ij} = 0 \forall i \notin L; \sum_j p_j x_{ij} = P_i$).

Causa: el modelo conoce el vocabulario, pero no la *estructura* típica (separar abrir de asignar y vincularlas con $x_{ij} \leq y_i$).

Desviación declarada. El benchmark final usa la rúbrica FOM-5 v2, que mantiene el criterio de equivalencia con una referencia y lo extiende a 30 problemas de distintos tipos.

2. Modelo seleccionado

Qwen/Qwen2.5-1.5B-Instruct, revisión 989aa79.

Modelo	Parám.	GSM8K	MATH	HumanEval
Qwen2.5	1.5B	73.2	55.2	61.6
Gemma-2-IT	2B	24.3	16.0	20.1
Phi-3-mini	3.8B	82.5	41.3	58.5

Es el **más pequeño** y el mejor en matemática simbólica y código. Phi-3-mini, con 2.5× parámetros, cometió errores del mismo tipo: el tamaño por sí solo no resolvía la falla.


3. Intervención: fine-tuning con QLoRA

Qué se hizo. Seguimos entrenando Qwen con ejemplos de la tarea: enunciados acompañados de su formulación correcta. Para que el entrenamiento cupiera en una T4 usamos QLoRA: el modelo original se congela y se comprime a 4 bits, y solo se entrena un pequeño *adaptador* agregado a sus capas (alrededor del 1% de los parámetros). El modelo aprende a producir la formulación, no a repetir el enunciado. El detalle de la configuración está en el notebook.

Vínculo con la falla. La falla es de *conocimiento estructural*, no de instrucciones: el prompt no puede enseñar patrones que el modelo no tiene. El ajuste los muestra con 1050 pares sintéticos de **50 familias** × 21 variantes (315 LP, 735 MILP), que incluyen localización, asignación, transporte, flujos, mochila, rutas y secuenciación.

Mismo modelo, dos variantes. Con el adaptador apagado el modelo es el baseline; encendido, es QLoRA. Ambos reciben el mismo prompt (solo el enunciado).

4. Pipeline



Cada problema del benchmark trae una **referencia** (una formulación correcta del problema) y una lista de **requisitos** (lo que toda respuesta correcta debe incluir: objetivo, cada restricción esencial y los dominios). Con ellos el juez

revisa la respuesta requisito por requisito y acepta formulaciones equivalentes con otra notación. El modelo evaluado nunca los ve.

5. Estrategias alternativas evaluadas

Antes de elegir el fine-tuning probamos intervenciones sobre el prompt en el caso de la Entrega 1. Esas respuestas se evaluaron con la rúbrica de localización de esa entrega, que mide fidelidad al negocio, eficiencia de la formulación, dominios, generalización y explicabilidad. Como es una escala distinta a la del benchmark final (sección 6), sus puntajes sirven para comparar las estrategias entre sí, no con los resultados de QLoRA.

Estrategia	Tipo	0–5
Prompting directo (baseline)	—	1.65
Chain of Thought	prompt	1.35
Descomposición en 3 pasos	descomp.	1.00
CoT + verificador con corrección	tool use	0.80
Conjuntos y parámetros por código	combinada	1.50
Mejor de 10 con verificador	tool use	1.50
One-shot, IR/JSON, blueprint, autorrevisión	prompt	—
QLoRA	fine-tuning	Sec. 6

Ninguna variante de prompt superó al baseline: el modelo seguía sin variable de apertura ni vinculación. Es consistente con Wei et al. (2022): el razonamiento guiado no ayuda a modelos pequeños.

6. Resultados contra el baseline

Conjunto: $n = 30$ **problemas** de tipos variados (LP, IP, MILP, redes, rutas, localización, secuenciación). Misma entrada y mismo criterio para ambas variantes: juez **FOM-5 v2** (Qwen3-14B, NF4) con referencia y requisitos.

$$F = 0.15D + 0.20O + 0.35R + 0.15A + 0.15G$$

D: decisiones y dominios; O: objetivo; R: restricciones; A: validez algebraica; G: generalización. Requisitos omitidos limitan su componente.

30 problemas	Baseline	QLoRA
Puntaje medio (0–5)	0.588	0.802
Casos con puntaje 0	21	12
Mejoran / igual / empeoran	14 / 8 / 8	

QLoRA mejora en promedio y reduce las respuestas sin formulación válida, pero el intervalo de confianza del cambio incluye el cero, así que **la mejora no es concluyente**. En el caso de la Entrega 1 el avance es claro ($0.65 \rightarrow 3.85$): aparecen la apertura y_i y el vínculo $x_{ij} \leq y_i$, aunque aún falta p_j en el objetivo.

7. Caso de falla: opt_02

Producción con horas extra. Baseline **1.30** $\rightarrow$ QLoRA **0.00**. Las horas extra $h \in [0, 20]$ amplían solo el trabajo y cuestan $10h$; hay topes de venta y un mínimo $x_C \geq 10$.

Correcto	QLoRA (6 de 6 requisitos incorrectos)
$\sum_i a_{Li} x_i \leq 140 + h$	$\sum_i a_{ik} x_i \leq b_k + y_k \quad \forall i, k$
h continua,	$y_k \in [0, 1]$ “si se usan k horas”
$0 \leq h \leq 20$	
$x_C \geq 10, x_i \leq d_i$	omitidas; agrega $x_i \leq b_k y_k$

Por qué falla. Ninguna familia de entrenamiento tiene horas extra, y *product mix* nunca incluye mínimos comprometidos. Las familias de activación (máquinas, cargo fijo) usan una binaria que abre capacidad ($\dots \leq u_i y_i$). El modelo reconoce “algo que amplía capacidad” y aplica esa plantilla en vez de leer la condición nueva. Como cada familia tiene una única formulación repetida 21 veces, el ajuste premia copiar estructura.

8. Límites conocidos

- **Plantillas:** 50 formulaciones canónicas; ante combinaciones no vistas puede empeorar (8 de 30 casos).
- **Nivel absoluto bajo:** 0.80/5; 12 de 30 siguen en 0.
- **Evidencia acotada:** una semilla, un juez automático y un IC que incluye 0.

Reproducción: secciones 1–4 del notebook en Colab T4; las 5–7 regeneran, juzgan y reentrenan.

Fuentes. [1] Qwen Team, *Qwen2.5 Technical Report*, arXiv:2412.15115. [2] Hu et al., *LoRA*, arXiv:2106.09685. [3] Dettmers et al., *QLoRA*, arXiv:2305.14314. [4] Wei et al., *Chain-of-Thought Prompting*, arXiv:2201.11903.