


Formulación LP/MILP desde español con QLoRA

Entrega 2 ù Inteligencia Artificial Generativa (580694) ù Universidad de Concepción

Rayen Muñoz ù Isidora Rivera ù Sebastián Soto ù José Luis Erices

Relevancia. Al localizar centros oftalmológicos, omitir el peso poblacional cambia el criterio de servicio; omitir el vínculo de apertura permite asignar demanda a centros cerrados. Estudiamos si un modelo pequeño en T4 puede producir borradores paramétricos verificables para revisión experta.



Continuidad y modelo

La salida exigida en la Entrega 1 es una formulación *paramétrica* equivalente al enunciado: conjuntos, parámetros, variables con dominios, objetivo y restricciones, sin resolver el óptimo. En la localización de centros oftalmológicos, Qwen omitió las aperturas y_i y la ponderación poblacional p_j , y contradijo la asignación única. Se requieren, entre otras condiciones,

$$\min \sum_{i,j} p_j d_{ij} x_{ij}, \quad \sum_i y_i = 2, \quad \sum_i x_{ij} = 1, \quad x_{ij} \leq y_i.$$

Elegimos **Qwen/Qwen2.5-1.5B-Instruct**, revisión de pesos 989aa7980e4c, por su tamaño (1.5B) y viabilidad en T4 frente a Gemma-2-2B-IT (2B) y Phi-3-mini (3.8B), también probados en la Entrega 1. Los benchmarks generales orientaron la elección; el resultado de esta tarea se mide abajo. One-shot, representación intermedia IR/JSON/DSL, blueprint y autorrevisión se exploraron antes; persistieron errores de estructura o repetición. Estas pruebas guiaron el diseño del ajuste.

Intervención y datos

QLoRA (adaptación de bajo rango sobre una base cuantizada) congela los pesos de Qwen en 4 bits NF4 y entrena matrices pequeñas de atención y MLP. LoRA $r = 16$, $\alpha = 32$; pérdida solo en la respuesta. El entrenamiento final usó 1050 entradas user-only, una época, semilla 42, LR $2 \cdot 10^{-4}$ y acumulación 8: **131 pasos, 982 s, 9.04 GiB** reservados en Colab T4.

Los datos son 50 familias $\times$ 21 variantes (315 LP, 735 MILP), con **50 formulaciones canónicas**. Verificamos IDs únicos, cero truncamientos bajo 1024 tokens y máscara assistant en 1050/1050. Dos pilotos 160/40 guiaron el formato; por cuota de GPU se omitió el desarrollo 840/210 previsto. El resultado final es exploratorio. Los hashes **SHA-256** identifican los bytes exactos de datos y adapter descargados para comprobar su integridad.

Benchmark FOM-5 v2


En los **mismos 30 problemas**, ambos generadores recibieron solo el enunciado, con decodificación determinista y tope de 1200 tokens. Se conservaron las 30 respuestas base y se generaron 30 QLoRA. Después, Qwen3-14B NF4 aplicó la rúbrica **FOM-5 v2** (0–5); actúa solo como juez, con referencia y requisitos reservados para esta fase. Calibración: 5/5.

La rúbrica combina decisiones/dominios D (15 %), objetivo O (20 %), restricciones R (35 %), validez algebraica A (15 %) y generalización G (15 %):

$$F = 0.15D + 0.20O + 0.35R + 0.15A + 0.15G.$$

Cada dimensión va de 0 a 5; los requisitos omitidos o erróneos limitan los componentes correspondientes. Sin formulación reconocible, $F \leq 1.5$.

30 casos oficiales	Base	QLoRA
FOM-5 v2 medio (0–5)	0.5884	0.8024
Casos con 0/5	21	12



Cambio medio pareado: **+0.2140/5**; IC bootstrap 95 % $[-0.2136, +0.7007]$ sobre 10 000 remuestreos de los 30 cambios. Como incluye cero, la evidencia no establece una mejora robusta. El caso de Entrega 1 se informa aparte: base determinista **0.650** $\rightarrow$ QLoRA **3.850**; persiste la omisión de p_j en el objetivo.

Falla y alcance

En `opt_02`, el puntaje bajó de **1.300 a 0.000**: las horas extra $h \in [0, 20]$ debían ampliar solo trabajo y costar $10h$; QLoRA inventó y_k y omitió la entrega mínima $x_C \geq 10$. El aprendizaje de plantillas puede sustituir condiciones concretas. Las familias comparten estructuras; tres casos oficiales tuvieron exposición histórica previa. Una sola semilla y un juez automático limitan la conclusión.

Reproducción

Repositorio: README, notebook Colab, adapter público, datos, respuestas y juicios por ID, evaluador y fuente $\text{\LaTeX}$. El notebook también puede repetir la generación y el juicio de los 30; el video muestra las dos rutas sobre el caso de Entrega 1. [Acceso a Entrega 2.](#)

Fuentes: Entrega 1 y archivos del proyecto; modelo Qwen2.5; QLoRA, Dettmers et al. (2023).