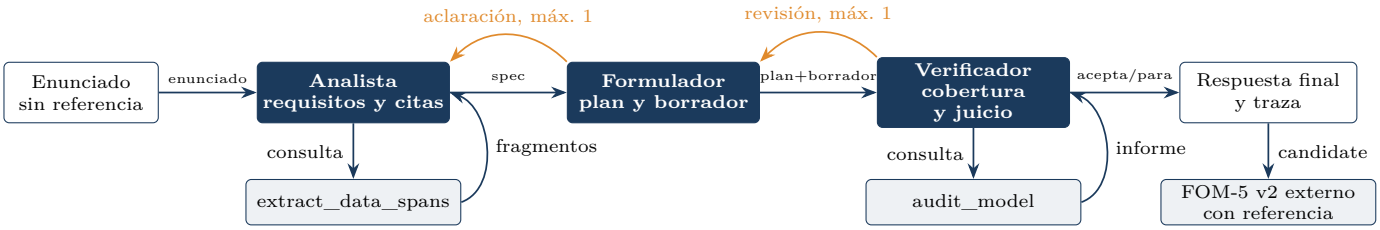
Formulación LP/MILP con tres agentes

Universidad de Concepción · Departamento de Ingeniería Civil Industrial

Inteligencia Artificial Generativa (580694) · Entrega 3 · 31 de octubre de 2026

Rayen Muñoz · Isidora Rivera · Sebastián Soto · José Luis Erices

Código abrir **Colab** abrir **Video** abrir



Problema y continuidad

Traducimos enunciados de optimización en español a conjuntos, parámetros, variables y dominios, objetivo y restricciones paramétricas. Un borrador incorrecto puede cambiar las decisiones admisibles de una empresa. En el caso de centros oftalmológicos, el prompting directo incluyó la población p_j en el objetivo, pero omitió la variable de apertura y su vínculo con la asignación. La Entrega 2 ajustó Qwen con QLoRA: recuperó esas restricciones y mejoró el formato, pero omitió p_j en el objetivo. Su media fue 0,802/5 en los 30 problemas del benchmark anterior.

Roles, mensajes y técnicas

Analista. Recibe ID, título y enunciado; devuelve `ProblemSpec` JSON con requisitos `U1...Un` y citas literales. La evidencia ancla cada condición al texto; puede releer una vez con `extract_data_spans` y luego entrega el análisis.

Formulador. Recibe el análisis y redacta un plan requisito–ecuación separado. Con el adaptador QLoRA produce `candidate` en las cinco secciones textuales de la Entrega 2. Puede pedir una aclaración al Analista; entrega el borrador al Verificador.

Verificador. Recibe enunciado, análisis y borrador. Construye `CoverageMap`, consulta opcionalmente `audit_model` y decide aceptar, pedir una revisión concreta o detenerse. El auditor comprueba estructura y cobertura; el agente juzga el significado matemático. El orquestador registra mensajes; topes: 20 llamadas, una aclaración, una revisión y 1 800/1 200 tokens de salida (Analista/otros). La referencia se reserva al juez.

Modelo y protocolo

Los tres roles usan **Qwen2.5-1.5B-Instruct**, revisión `989aa79`, con decodificación determinista en T4. El adaptador QLoRA de la Entrega 2 se activa solo al redactar `candidate`. En ocho casos de desarrollo, apagarlo en el Verificador redujo los fallos de formato de seis a uno. La configuración quedó fijada en `v3-freeze` antes de medir la muestra de 15 casos.

La métrica **FOM-5 v2** (0–5) aplica el mismo juez externo Qwen3-14B a todas las respuestas: $0{,}15D + 0{,}20O + 0{,}35R + 0{,}15A + 0{,}15G$, con límites por requisitos omitidos. D: decisiones/dominios; O: objetivo; R: restricciones; A: álgebra; G: generalización. El juez ve referencia y requisitos; los agentes no.

Comparación pareada · 15 problemas

Sistema	Media	Δ E2	Δ full
Prompt directo · Entrega 1	0,909	−0,221	–
QLoRA · Entrega 2	1,130	ref.	–
Tres agentes · completo	0,739	−0,391	ref.
Sin citas del Analista	0,563	−0,567	−0,177
Sin plan del Formulador	1,099	−0,031	+0,360
Sin `audit_model`	1,120	−0,010	+0,380
Sin revisión del borrador	1,120	−0,010	+0,380

Las variantes comparten los primeros 15 enunciados del benchmark de 30; E1 y E2 son respuestas archivadas. Los Δ son diferencias pareadas por ID. Frente a E2, *full* mejora 3 casos, empata 6 y empeora 6; IC 95 % bootstrap de Δ: $[-1{,}399; 0{,}549]$. Frente al baseline, su Δ es −0,169. No se demuestra mejora. Sin auditor o sin revisión se obtienen las mismas puntuaciones, +0,380 frente a *full* (IC 95 %: $[0{,}079; 0{,}770]$); 14/15 textos finales coinciden entre ambas ablaciones. Las 75 generaciones acabaron sin aceptación: 43 fallos de formato, 32 presupuestos agotados y cuatro textos vacíos. FOM-5 v2 puntuó el texto final guardado. *Full* consumió 14 560 tokens y 2,7 minutos por caso.

Lectura del resultado

El caso oftalmológico es diagnóstico y queda fuera de la media de 15. En las respuestas archivadas, FOM-5 v2 puntúa **0,65/5** el baseline, **3,85/5** QLoRA y **2,60/5** los tres agentes. Esta última recupera p_j en el objetivo, pero omite el vínculo $x_{ij} \le y_i$ y escribe mal la apertura de dos centros. El Verificador detectó problemas, pero agotó su salida sin una corrección concreta; por eso la mejor puntuación respecto del baseline no implica mejora sobre la Entrega 2.

Límites y reproducción

La presencia de una ecuación o un símbolo no prueba equivalencia matemática. `audit_model` detecta omisiones estructurales y notación inconsistente; el juicio semántico del Verificador puede fallar. La traza diagnóstica archivada muestra ese límite. El cuaderno público ejecuta el caso en vivo y presenta sus mensajes; la última sección reproduce las cinco variantes y la evaluación sobre 15 casos.

Artefactos: código, prompts, respuestas, trazas y métricas en el repositorio enlazado arriba.