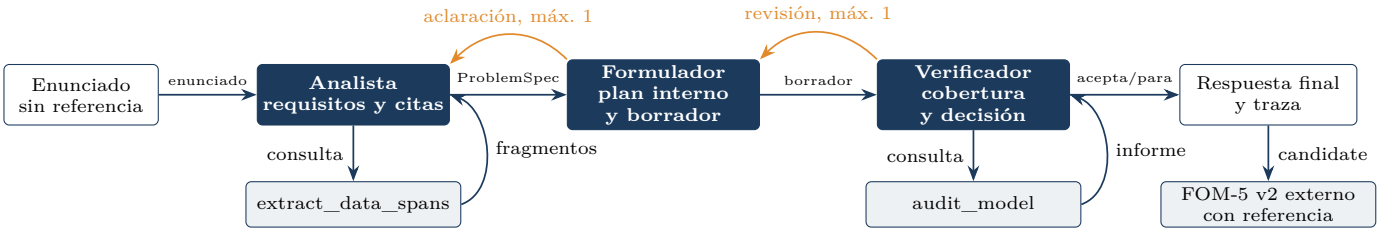
Formulación LP/MILP con tres agentes

Universidad de Concepción · Departamento de Ingeniería Civil Industrial

Inteligencia Artificial Generativa (580694) · Entrega 3 · 31 de octubre de 2026

Rayen Muñoz · Isidora Rivera · Sebastián Soto · José Luis Erices

Código abrir **Colab** abrir **Video** abrir



Problema y continuidad

Traducimos enunciados LP/MILP en español a conjuntos, parámetros, variables y dominios, objetivo y restricciones. Errores en índices o restricciones cambian las decisiones admisibles. En centros oftalmológicos, el prompting directo incluyó la población p_j en el objetivo, pero omitió la apertura y su vínculo con la asignación. La Entrega 2 ajustó Qwen mediante QLoRA (adaptación de bajo rango de un modelo cuantizado): recuperó esas restricciones y el formato, pero omitió p_j. Su media histórica fue 0,802/5 en 30 problemas.

Roles, mensajes y técnicas

Analista. Recibe ID, título y enunciado; devuelve `ProblemSpec` JSON con datos, decisiones y requisitos `U1...Un` respaldados por citas. Puede usar `extract_data_spans` para localizar cantidades y unidades literales; la herramienta no infiere ecuaciones.

Formulador. Recibe enunciado y `ProblemSpec`; prepara un plan interno requisito–ecuación. Con el adaptador QLoRA redacta `candidate`, la formulación textual en cinco secciones. Puede pedir una aclaración al Analista; solo el borrador pasa al Verificador.

Verificador. Recibe enunciado, análisis y borrador. Construye `CoverageMap` (requisito–ecuación) y decide aceptar, pedir revisión o detenerse. Puede consultar `audit_model`, que comprueba símbolos, dominios, índices y cobertura con reglas deterministas; el agente juzga el sentido matemático. El orquestador transmite y registra mensajes; topes: 20 llamadas, una aclaración, una revisión y 1 800/1 200 tokens de salida (Analista/otros). La referencia se reserva al juez.

Modelo y protocolo

Los tres roles usan **Qwen2.5-1.5B-Instruct**, revisión `989aa79`, con decodificación determinista en T4. El adaptador QLoRA se activa solo al redactar `candidate`. En ocho casos de desarrollo, apagarlo en el Verificador redujo los fallos de formato de seis a uno. El tag `v3-freeze` fijó código, prompts y límites antes de medir el benchmark.

Después de generar, **FOM-5 v2** (0–5) usa un segundo modelo, **Qwen3-14B** (revisión `40c0698`), como juez: $0{,}15D + 0{,}20O + 0{,}35R + 0{,}15A + 0{,}15G$, con límites por requisitos omitidos. D: decisiones/dominios; O: objetivo; R: restricciones; A: álgebra; G: generalización. Solo el juez ve la referencia; cargar y ejecutar ambos modelos aumenta el costo de GPU.

Comparación pareada · 15 problemas

Sistema	Media	Δ QLoRA	Δ full
Prompt directo · Entrega 1	0,909	−0,221	–
QLoRA · Entrega 2	1,130	ref.	–
Tres agentes · completo	0,739	−0,391	ref.
Sin citas del Analista	0,563	−0,567	−0,177
Sin plan del Formulador	1,099	−0,031	+0,360
Sin `audit_model`	1,120	−0,010	+0,380
Sin revisión del borrador	1,120	−0,010	+0,380

Por límite de cómputo ejecutamos los primeros 15 de los 30 enunciados y repartimos las cinco variantes entre varias cuentas de Colab T4; todas usan los mismos 15. Baseline y QLoRA son respuestas archivadas. Los Δ son diferencias pareadas por ID. Frente a QLoRA, *full* mejora 3 casos, empata 6 y empeora 6; IC 95 % bootstrap de Δ: [−1,399; 0,549]. Frente al baseline, su Δ es −0,169. No se demuestra mejora. Sin auditor o sin revisión se obtienen las mismas puntuaciones, +0,380 frente a *full* (IC 95 %: [0,079; 0,770]); 14/15 textos finales coinciden entre ambas ablaciones. Las 75 generaciones acabaron sin aceptación: 43 fallos de formato, 32 presupuestos agotados y cuatro textos vacíos. FOM-5 v2 puntuó el texto final guardado. *Full* consumió 14 560 tokens y 2,7 minutos por caso.

Lectura del resultado

El caso oftalmológico es diagnóstico y queda fuera de la media de 15. En las respuestas archivadas, FOM-5 v2 puntúa **0,65/5** el baseline, **3,85/5** QLoRA y **2,60/5** los tres agentes. Esta última recupera p_j en el objetivo, pero omite el vínculo $x_{ij} \le y_i$ y escribe mal la apertura de dos centros. El Verificador detectó problemas, pero agotó su salida sin una corrección concreta; por eso la mejor puntuación respecto del baseline no implica mejora sobre la Entrega 2.

Límites y reproducción

La presencia de una ecuación o un símbolo no prueba equivalencia matemática. `audit_model` detecta omisiones estructurales y notación inconsistente; el juicio semántico del Verificador puede fallar. La traza diagnóstica archivada muestra ese límite. El cuaderno público ejecuta el caso en vivo y presenta sus mensajes; la última sección reproduce las cinco variantes y la evaluación sobre 15 casos.

Artefactos: código, prompts, respuestas, trazas y métricas en el repositorio enlazado arriba.