

Formulación automática de modelos de optimización desde lenguaje natural

Deliverable 1 — Generative Artificial Intelligence (580694)

Rayen Muñoz • Isidora Rivera • Sebastián Soto • José Luis Erices

Notebook

Google Colab

Objetivo

convertir una descripción textual de un problema de optimización en una formulación matemática correcta, paramétrica y verificable, sin resolverla.

1. Especificación de la tarea

Entrada. Descripción en lenguaje natural de un problema determinista de programación lineal o lineal entera mixta, con objetivos y relaciones operacionales, de nivel universitario.

Salida. Formulación del modelo matemático, sin resolver el óptimo, estructurado en conjuntos, parámetros, variables de decisión, función objetivo y restricciones, con índices y dominios cuando correspondan.

Criterio de corrección. Debe ser matemáticamente equivalente a una referencia: símbolos definidos, dimensiones consistentes, decisiones y restricciones necesarias presentes y ausencia de condiciones inventadas.

Para la evaluación de los modelos escogidos, se realizó este entregable con un ejemplo de diagnóstico.

Caso diagnóstico: localización p-mediana

Elegir exactamente 2 de 3 ubicaciones y asignar 5 sectores minimizando distancia ponderada por población. La respuesta de referencia explícita cada componente:

Conjuntos: I : ubicaciones, J : sectores de demanda.

Parámetros: d_{ij} : distancia, p_j : población, $K = 2$: centros a instalar.

Variables: $y_i \in \{0, 1\}$: apertura, $x_{ij} \in \{0, 1\}$: asignación.

Función objetivo y restricciones:

$$\begin{aligned} \min \quad & \sum_{i \in I} \sum_{j \in J} p_j d_{ij} x_{ij} \\ \text{s.a.} \quad & \sum_{i \in I} x_{ij} = 1 \quad \forall j \in J, \\ & x_{ij} \leq y_i \quad \forall i \in I, j \in J, \\ & \sum_{i \in I} y_i = K, \quad x_{ij}, y_i \in \{0, 1\}. \end{aligned}$$

Así se verifica si el SLM preserva simultáneamente asignación, apertura y ponderación de demanda, independientemente de los datos numéricos.

2. Fallas observadas

La evidencia final usa *zero-shot*: solo el caso y la estructura de salida. Un ensayo *one-shot* con ejemplo y/o reglas de formato produjo resultados peores, por lo que se descartó.

Modelo	Falla observada
Qwen2.5	Reduce la asignación a una dimensión, introduce productos entre variables y omite p_j del objetivo.
Gemma 2	Colapsa índices; no expresa consistentemente cardinalidad ni vinculación asignación-apertura.
Phi-3 Mini	Confunde índices/decisiones y genera restricciones que omiten o alteran la lógica de apertura.

3. Selección de modelos y benchmarks

Se proponen tres modelos, todos muy por debajo del límite de 8B: **Qwen2.5-1.5B-Instruct** (1.5B), **Gemma-2-2B-IT** (2B) y **Phi-3-mini** (3.8B). Para la selección usamos benchmarks generales como evidencia de capacidad base, no como métrica final del proyecto:

- GSM8K**: razonamiento aritmético multietapa desde problemas verbales.
- MATH**: razonamiento matemático y manipulación simbólica de mayor dificultad.
- BBH**: razonamiento composicional/multietapa; está reportado para los tres candidatos.
- IFEval**: señal de seguimiento de instrucciones con restricciones verificables; está reportado explícitamente para SmoLLM2-Instruct.

Tabla 1. Rendimiento publicado de los candidatos en reportes técnicos.

Benchmark	Gemma-2 (2B)	Phi-3-mini (3.8B)	Qwen2.5 (1.5B)
GSM8K	24.3	82.5	73.2
MATH	16.0	41.3	55.2
HumanEval	20.1	58.5	61.6
IFEval	–	–	42.5

Comparación de modelos

- Qwen2.5-1.5B-Instruct**: Ofrece la mejor relación tamaño-rendimiento del conjunto. Con apenas 1.5 billones de parámetros, supera a Gemma-2 en todos los *benchmarks* comparables y a Phi-3-mini en pruebas críticas de lógica abstracta y programación, como MATH (55.2) y HumanEval (61.6). Aunque en la prueba empírica falló al omitir la variable binaria de localización y plantear inecuaciones contradictorias, su sobresaliente capacidad en notación simbólica lo convierte en el candidato principal para estudiar si una arquitectura ultraligera puede aprender la estructura algebraica faltante (como la restricción de vinculación $x_{ij} \leq y_i$). Adicionalmente, su tamaño minimiza el consumo de VRAM.
- Gemma-2-2B-IT**: Sus resultados considerablemente inferiores en matemáticas y código (MATH 16.0, HumanEval 20.1) se reflejaron en sus pruebas, donde colapsó la dimensionalidad de la matriz de asignación.
- Phi-3-mini (3.8B)**: Representa el extremo superior de capacidad y tamaño del conjunto evaluado, obteniendo el mejor puntaje en resolución matemática secuencial (GSM8K 82.5). No obstante, su intento de formulación empírica sufrió de ceguera estructural, al inventar restricciones y mezclar índices de los conjuntos. Su presencia en el estudio permite contrastar si el simple hecho de casi triplicar los parámetros respecto a Qwen2.5 es suficiente para mitigar naturalmente los errores de índices, cardinalidad y vinculación.

Selección del modelo principal

Para la fase de implementación, el modelo seleccionado es **Qwen2.5-1.5B-Instruct**. A pesar de que todos los candidatos exhibieron fallas críticas en las formulaciones de prueba, los problemas de optimización de nivel universitario exigen un análisis detallado e interpretación rigurosa de los enunciados. El dominio absoluto de Qwen2.5 en las métricas de

MATH y HumanEval evidencia que posee el motor de razonamiento simbólico más avanzado del grupo. Esta superioridad algorítmica, sumada a su eficiencia en memoria, lo posiciona como la opción más robusta para iterar, depurar y programar la solución de los problemas de optimización de alto nivel a los que se verá expuesto durante el semestre.

4. Factibilidad de ejecución

Los tres modelos seleccionados se ejecutan en el mismo Google Colab gratuito con GPU T4, cargando un checkpoint a la vez mediante **transformers/accelerate**. El notebook contiene la carga, inferencia y el caso diagnóstico para Qwen2.5, Gemma-2 y Phi-3 Mini; cuando se cambia de arquitectura se debe liberar la VRAM antes de cargar el siguiente modelo. La evidencia reproducible está disponible en [Google Colab](#).

El rango de 1.5B–3.8B hace viable repetir inferencias y modificar prompts sin GPU local dedicada. La misma configuración permite mantener fijo el hardware para las etapas posteriores, de modo que las diferencias observadas puedan atribuirse al modelo o a la estrategia de adaptación y no a cambios de infraestructura.

Síntesis

La tarea elegida tiene una salida inequívocamente verificable y una falla concreta: los SLM comprenden el contexto general, pero rompen la coherencia entre índices, variables y restricciones al traducirlo a álgebra. Los tres candidatos satisfacen el límite de tamaño y la factibilidad de ejecución; Qwen2.5 destaca por su relación rendimiento-parámetros, mientras Gemma-2 y Phi-3 Mini entregan contrastes de capacidad útiles para comprobar si la mejora futura proviene de la adaptación estructurada.

Fuentes.

- Gemma Team, *Gemma 2: Improving Open Language Models at a Practical Size*, 2024.
- Microsoft, *Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone*, 2024.
- Qwen Team, *Qwen2.5 Technical Report*, arXiv:2412.15115, 2024.